RUNELAB

Big Data & Data Engineering

Uçtan Uca Veri Yolculuğu Eğitim

Enes Fehmi Manan

Ben Kimim?

- **Data Scientist @ Fibabanka:** Analitik işler, Kredi risk modelleri optimizasyonu ve LLM/VLM bazlı agentic veya RAG tabanlı GenAI mimarileri geliştiriyorum.
- **Entrepreneur @ PathWay:** 50+ çalışanı olan şirketler için yetenek yönetim ve nine-box sistemi.
- **ML Dev Advocate @ RuneLab.ai:** İleri seviye ML ve GenAI konularında canlı yayınlar, workshoplar ve eğitim içerikleri üreterek topluluğa teknik liderlik yapıyorum.
- **Community Lead @ Turkish AI Community:** Eğitim programları tasarlıyor, Üniversite kulüplerine kapsamlı eğitimler veriyor ve açık kaynak ekosistemini büyütüyorum.
- **Instructor & Organizer @ Dev MultiGroup:** Uçtan uca GenAI/ML Bootcampleri ('Zero2End' & GenAI Fundamentals) tasarlıyor ve podcast serilerini yönetiyorum.

BÖLÜM 1

Veri Dünyasındaki Roller

Data Engineer, Data Analyst ve Data Scientist kimdir? Sınırları nerede başlar, nerede biter?

Veri Dünyasındaki Roller: Data Engineer

Veri mühendisleri, veri mimarisinin temelini atan mimarlardır. Verinin A noktasından B noktasına güvenilir bir şekilde akmasını sağlarlar.

- **Altyapı Kurulumu:** Ölçeklenebilir veri ambarları ve veri gölleri inşa eder.
- **Pipeline Geliştirme:** Karmaşık ETL (Extract, Transform, Load) ve ELT süreçlerini kodlar ve otomatikleştirir.
- **Sinerji Yaratma:** Makine öğrenmesi süreçlerinin (MLOps) ihtiyaç duyduğu temiz, yapılandırılmış ve güncel veriyi modelleme ekipleri için hazır hale getirir.

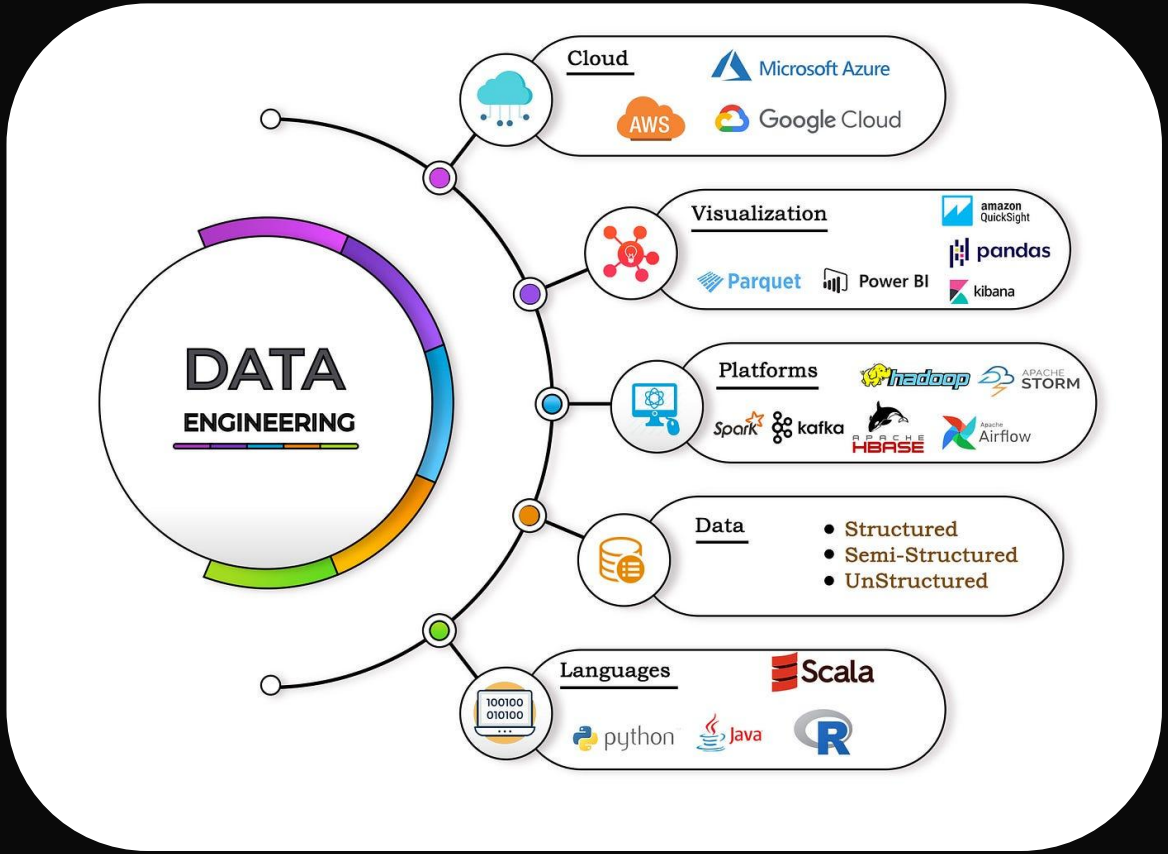

Veri Dünyasındaki Roller: Data Analyst

Veri analistleri, geçmiş ve mevcut verilere odaklanarak "Ne oldu?" ve "Neden oldu?" sorularına yanıt arayan iş zekası (BI) uzmanlarıdır.

- **İçgörü Çıkarma:** Karmaşık veri setlerinden iş kararlarını yönlendirecek anlamlı sonuçlar türetir.
- **Görselleştirme:** Şirket yöneticilerinin anlayabileceği etkileşimli dashboard'lar (PowerBI, Tableau) ve raporlar hazırlar.
- **Köprü Görevi:** Teknik altyapı ekipleri (Mühendisler) ile iş birimleri (Business/Pazarlama) arasında çevirmen rolü üstlenir.

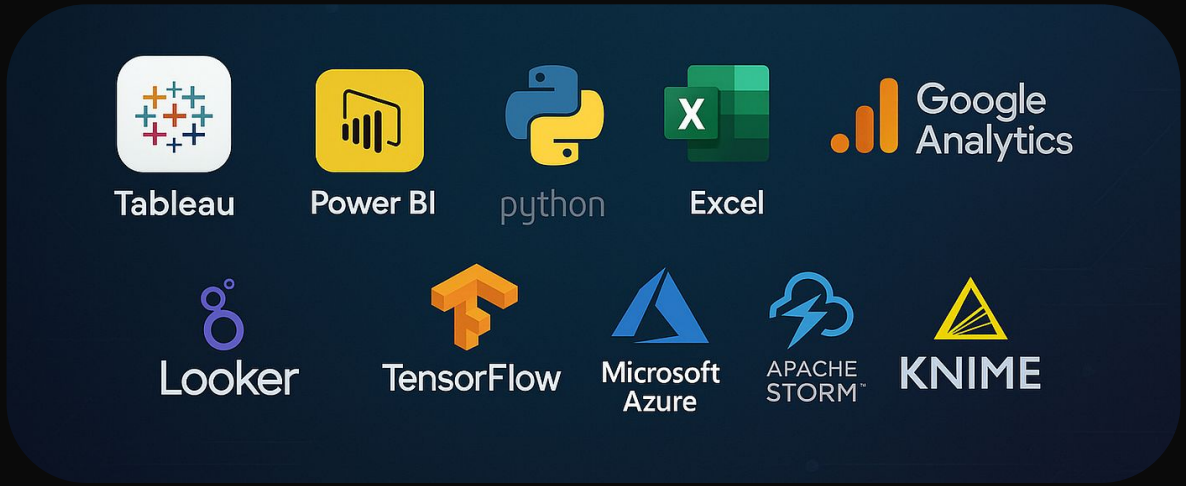

Veri Dünyasındaki Roller: Data Scientist

Veri bilimciler, istatistik ve algoritmaları kullanarak "Gelecekte ne olacak?" sorusuna odaklanır ve öngörüsel sistemler geliştirir.

- **Tahmin Modelleri:** Makine öğrenmesi ve yapay zeka algoritmaları kullanarak gelecekteki trendleri, riskleri veya müşteri davranışlarını tahmin eder.
- **İleri İstatistik:** A/B testleri, hipotez testleri ve karmaşık matematiksel optimizasyonlar gerçekleştirir.
- **Gelişmiş AI Çözümleri:** Doğal Dil İşleme (NLP) ve Bilgisayarlı Görü gibi spesifik yapay zeka ürünlerini hayata geçirir.

BÖLÜM 2

Big Data Konseptleri

Büyük veri nedir, hacmi neye göre belirlenir ve özellikleri (5V) nelerdir?

"Büyük Veri" Büyük de, Kime Göre Büyük?

Büyüklük görecelidir. 90'larda 1 Gigabyte "büyük veri" olarak kabul edilirken, bugün sıradan cep telefonlarımızda 256 Gigabyte veri taşıyoruz.

Öyleyse sınır nerede başlıyor? Sınır gigabaytlar veya petabaytlar değil, donanım ve altyapı sınırlarıdır.

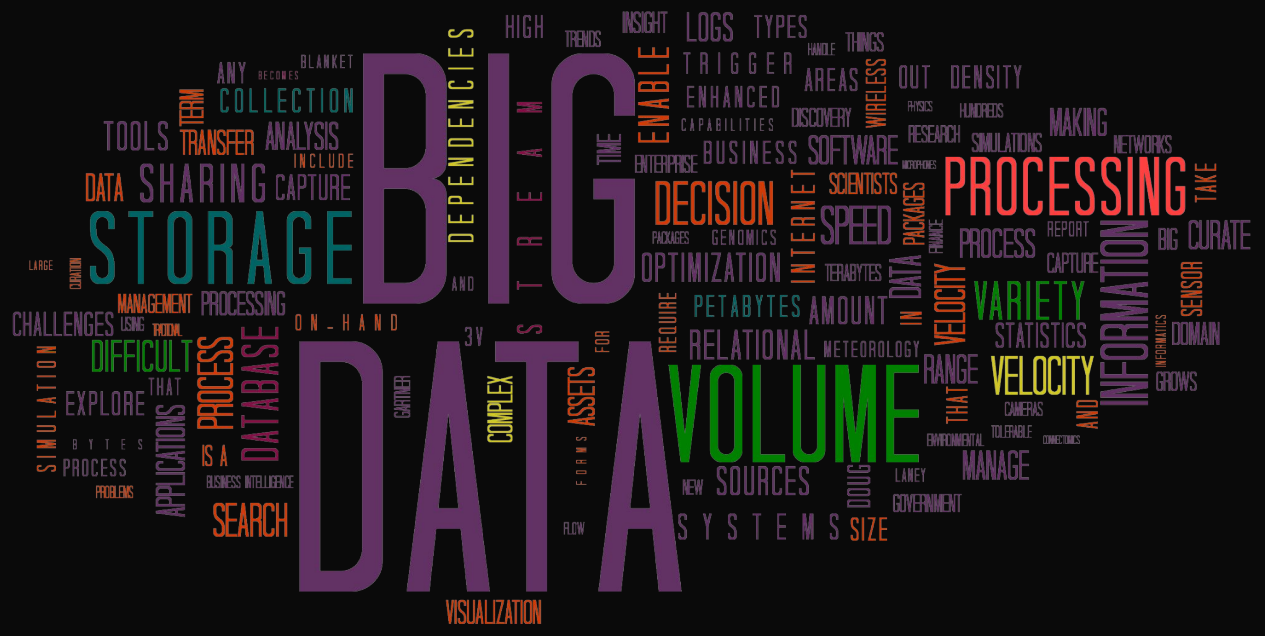

"Kırılma Noktası"

Büyük veri kavramı; verilerinizin hacminin, hızının veya karmaşıklığının **artık tek bir geleneksel sunucu/makine üzerinde işlenemediği veya depolanamadığı** noktada başlar.

Büyük Verinin Karakteristiği: The 5V's

- **Volume (Hacim):** Verinin fiziksel boyutudur. Artık Megabaytlar değil; Terabaytlar, Petabaytlar ve Eksabaytlar seviyesinde devasa veri depolanır.
- **Velocity (Hız):** Verinin üretilme ve işlenme hızıdır. Gece çalışan Batch (yığın) işlemlerden, saniyede milyonlarca olayın aktığı Stream (gerçek zamanlı) işlemlere geçiştir.
- **Variety (Çeşitlilik):** Verinin formatıdır. Sadece satır ve sütunlardan oluşan Tablosal veri değil; Metin, Ses, Video, JSON ve Log dosyaları gibi yapılandırılmamış verilerdir.
- **Veracity (Doğruluk):** Çeşitli kaynaklardan gelen devasa verinin güvenilirliği, tutarlılığı ve gürültüden (hatalı veri) ne kadar arındırılmış olduğudur.
- **Value (Değer):** Tüm bu veriyi depolamanın ve işlemenin sonucunda iş birimlerine, karlılığa ve kararlara sağlanan somut ticari faydadır.

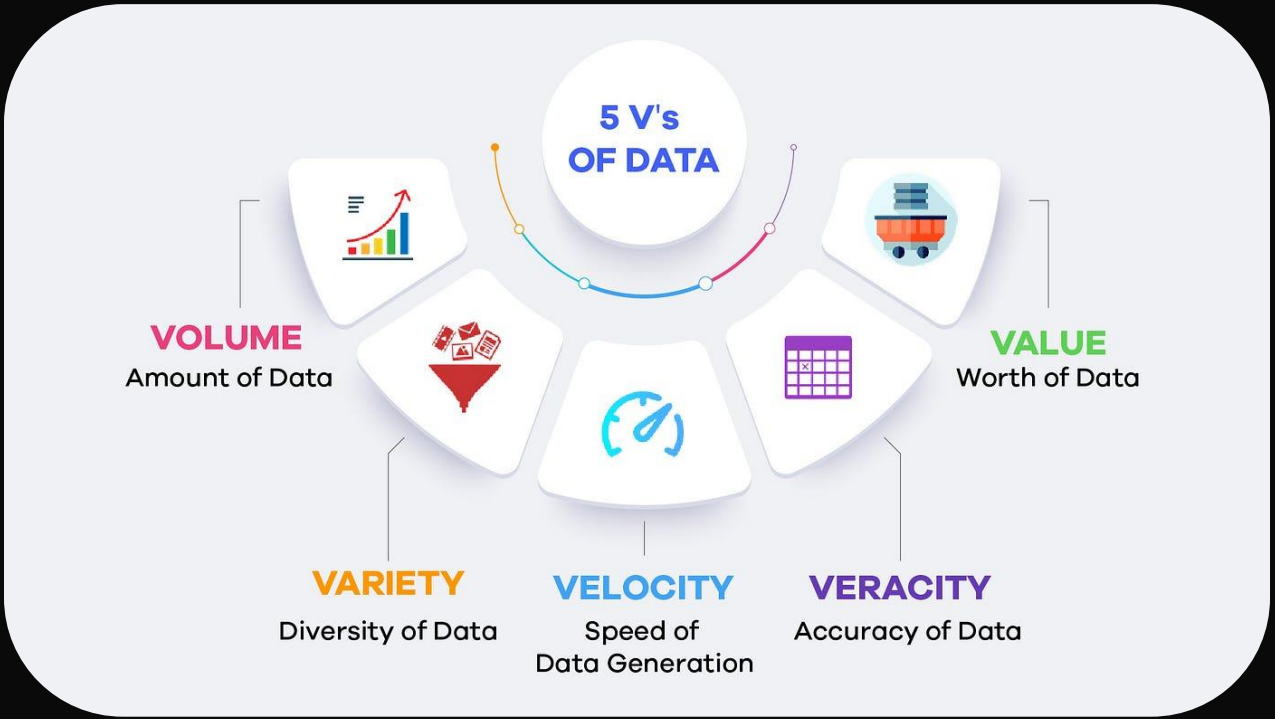

Geleneksel DB'ler Nerede Tıkanır?

Yatayda Ölçeklenme Sorunu

Geleneksel ilişkisel veritabanları (RDBMS) dikeyde (daha büyük RAM/CPU) büyümek üzere tasarlanmıştır. Veri aşırı büyüdüğünde yanına ucuz sunucular ekleyerek "yatayda" (Scale-out) ölçeklenmekte zorlanırlar.

Yüksek Yazma Hızı (I/O) Sınırı

Saniyede yüz binlerce IoT sensör verisinin veya web logunun geldiği (Streaming) senaryolarda, RDBMS'lerin katı işlem garantileri (ACID) ve kilit mekanizmaları (Locks) eşzamanlı yazma performansını felce uğratır.

Şema ve Çeşitlilik Baskısı

Klasik veritabanları veriyi önceden tanımlı tablolara sıkıştırmak ister. Ancak sosyal medya verisi, videolar veya JSON dosyaları gibi yapılandırılmamış (unstructured) veriler bu katı şemalara uymaz.

BÖLÜM 3 & 4 & 5

Mimari ve Altyapı

Dağıtık sistemler, veritabanı stratejileri ve modern veri mühendisliği ardındaki temeller.

Bölüm 3: Distributed Systems & Paradigms

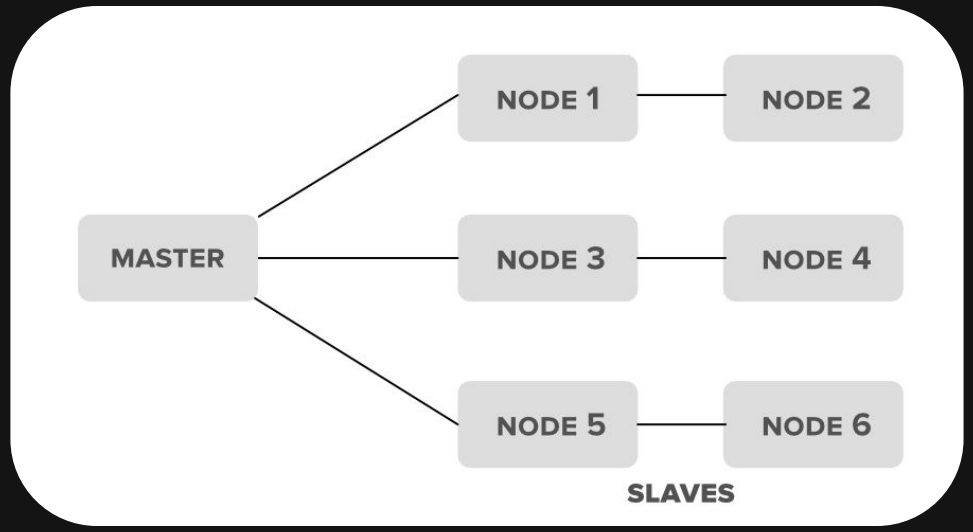

Ölçeklendirme Mantığı & Clusters

Sistemleri büyütürken donanımı güçlendirmek (Scale-Up) yerine sunucu sayısını artırmak (Scale-Out) modern yaklaşımdır. Node'lar bir araya gelerek Cluster yapılarını oluşturur, böylece donanım çökse dahi sistemin çalışmaya devam etmesi (Fault Tolerance) sağlanır.

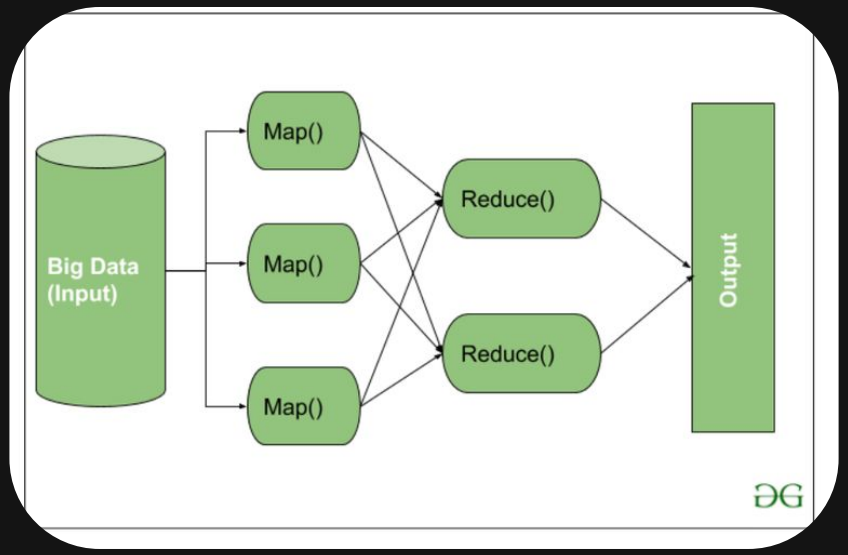

Hadoop & MapReduce

Hadoop ekosistemi ve HDFS ile veriyi parçalayarak dağıtık depolama devrimi başlamıştır. MapReduce paradigmasının özü; hesaplama işlemi için petabaytlarca veriyi tek merkeze taşımak yerine, hesaplama kodunu verinin bulunduğu sunuculara (node) götürmektir.

Bölüm 4: Databases & Storage

- **RDBMS vs. NoSQL:** Katı şemalara sahip ilişkisel veritabanlarına karşı; esnek şemalı Document, Key-Value, Column-family ve Graph veritabanı çözümleri bulunur.
- **OLTP vs. OLAP:** Anlık, çok sayıda ve küçük işlemleri yöneten operasyonel sistemler (OLTP) ile büyük veri üzerinde karmaşık analitik sorgular koşan sistemlerin (OLAP) ayrışması.
- **Storage Formats:** Analitik iş yüklerinde veri okuma performansını maksimize etmek için tüm satırı değil, sadece ihtiyaç duyulan sütunları getiren (Row-oriented yerine Column-oriented) depolama formatları seçilir.

Bölüm 5: Data Engineering Fundamentals

What is a Data Pipeline?

Verinin kaynaktan (A noktası) alınıp, doğrulanarak, filtrelenerek ve şekillendirilerek kullanılacağı nihai hedefe (B noktası) ulaştırılmasını sağlayan otomatik iş akışları ve yolculuğudur.

Integration: ETL vs. ELT

Verinin kaynağından çekildikten sonra dönüştürülüp hedefe yüklenmesi (ETL) ile önce ham olarak hedefe yüklenip (Cloud DWH), güçlü donanım üzerinde hedefin içinde dönüştürülmesi (ELT) arasındaki paradigma farkıdır.

Batch vs. Stream

Büyük veri yığınlarının gece saatlerinde veya periyodik zaman dilimlerinde (Batch Processing) işlenmesi ile akan verinin üretildiği anda milisaniyelik gecikmelerle (Stream Processing) anlık olarak işlenmesidir.

BÖLÜM 6 & 7

Modern Veri Yığınları

Data Warehouse, Lakehouse mimarileri ve modern ekosistem teknolojileri.

Bölüm 6: Modern Data Architectures

Data Warehouse

İş zekası (BI) ve analitik sorgular (OLAP) için optimize edilmiş, yapılandırılmış tarihsel verilerin tutulduğu kurumsal ve merkezi veri ambarı sistemidir.

Data Lake

Sadece yapılandırılmış değil, metin, ses ve görüntü gibi yapılandırılmamış tüm kurumsal verinin ham haliyle, düşük depolama maliyetleriyle tutulduğu sistemdir.

Data Lakehouse

Veri gölünün esnekliği ve düşük maliyeti ile veri ambarının performans, kalite ve ACID işlem garantilerini tek bir mimaride birleştiren yeni nesil yapıdır.

Bölüm 7: Technologies & Modern Data Stack

- **The Foundations:** SQL & Python, veri işleme, analiz ve altyapı yönetiminde ekosistemin tartışmasız en temel yapıtaşlarıdır.
- **Compute Engines:** Apache Spark, Apache Flink ve Kafka ile yüksek performanslı, dağıtık toplu (batch) ve gerçek zamanlı (stream) hesaplamalar yapılır.
- **Cloud Platforms:** Snowflake, Google BigQuery ve Databricks, sıfır kurulum gerektiren modern bulut veri ambarı ve lakehouse mimarilerini temsil eder.
- **Orchestration & Transformation:** Bağımlılıkları yöneten Airflow (orkestrasyon) ve SQL tabanlı dönüşüm standartı olan dbt (data build tool).

Modern Veri Yığını: Motorlar ve Orkestrasyon

Apache Kafka (Event Streaming)

Sistemin **"merkezi sinir ağı"dır**. Kaynaklardan gelen milyonlarca anlık mesajı/olayı (event) gerçek zamanlı olarak yakalar, kaybetmeden güvenle tamponlar ve hedeflere dağıtır.

Apache Spark (Batch Processing)

Sistemin **"ağır işçisi"dir**. Devasa boyutlardaki geçmiş veriyi (batch) RAM üzerinde dağıtık olarak çok hızlı bir şekilde işler, temizler ve analize veya modele hazır hale getirir.

Apache Flink (Stream Processing)

Sistemin **"hızlı düşünürü"dür**. Kafka'dan akan veriyi beklemeden, saniyenin altındaki (milisaniye) gecikmelerle anında işler ve gerçek zamanlı (real-time) reaksiyonlar üretir.

Apache Airflow (Orchestration)

Sistemin **"orkestra şefi"dir**. Hangi veri işinin (task) ne zaman çalışacağını, başarısız olursa ne yapılacağını (DAGs) yönetir. Tüm veri boru hattını (pipeline) zamanlar ve izler.

Büyük Veri Senaryosu: Gerçek Zamanlı Karar Akışı

Örnek: Kredi Kartı Dolandırıcılık (Fraud) Tespiti veya Dinamik Fiyatlandırma.

1. Veri Üretimi

Müşteri e-ticaret sitesinde ödeme tuşuna basar veya POS cihazından kartını çeker (Event Source).

2. Veri Yakalama

Saniyede binlerce işlem, Apache Kafka gibi mesajlaşma sistemlerine (Message Broker) mili-saniyeler içinde iletilir.

3. Stream İşleme

Apache Flink/Spark Streaming veriyi anlık yakalar, geçmiş müşteri profili (Feature Store) ile birleştirir.

4. ML Inference

Önceden eğitilmiş makine öğrenmesi modeli bu veriyi alır ve anında "Risk Skoru" (Örn: %95 dolandırıcılık) üretir.

5. Aksiyon

Skora göre işlem otomatik reddedilir, müşteriye SMS gider veya müşteri hizmetleri ekranına uyarı düşer.

BÖLÜM 8 & 9 & 10

Makine Öğrenmesi & GenAI

Veri biliminin temelleri, model operasyonları (MLOps) ve Generative AI'ın veri mühendisliğine etkisi.

Bölüm 8: Machine Learning Fundamentals

What is ML & Types

Klasik yazılım geliştirmenin kural tabanlı yapılarından (If/Else), verideki gizli örüntüleri çıkararak kendi öğrenen algoritmik sistemlere geçiştir. Öğrenme tipleri; etiketli verilerle çalışan Supervised (Gözetimli), etiketsiz verilerden küme çıkaran Unsupervised (Gözetimsiz) ve bir ajanın ortama göre deneme yanılma yaptığı Reinforcement (Pekiştirmeli) Learning olarak ayrılır.

Core Pipeline & Algorithms

Standart bir ML projesi şu süreçten geçer: Data Prep →Training → Evaluation → Inference.

Sınıflandırma, regresyon ve kümeleme ana görevlerdir. Finans ve skorlama gibi tablosal verilerde ağaç tabanlı modeller (XGBoost) sıklıkla tercih edilirken, görüntü ve metin (NLP) alanlarında Yapay Sinir Ağları öne çıkar.

Bölüm 9: Bridge to Data Science

Feature Engineering

Makine öğrenmesi algoritmalarının anlayabilmesi ve modellerin tahmin gücünü maksimize etmesi için, karmaşık ham veriyi anlamlı sinyallere (feature) dönüştürme sanatıdır.

Feature Store Concept

Zorlukla üretilen bu "feature"ların şirket içinde merkezi olarak saklanması, versiyonlanması ve farklı ekipler tarafından production ortamında tekrar tekrar kullanılmasını sağlayan yapıdır.

Data Drift & Inference

Canlıdaki modeli besleyen verinin dağılımının zaman içindeki değişimine (Data/Concept Drift) denir. Model eğitirken (Training) kullanılan akış ile canlıda tahmin (Inference) yaparken kullanılan pipeline'lar farklılık gösterir.

Bölüm 10: GenAI in Data Engineering

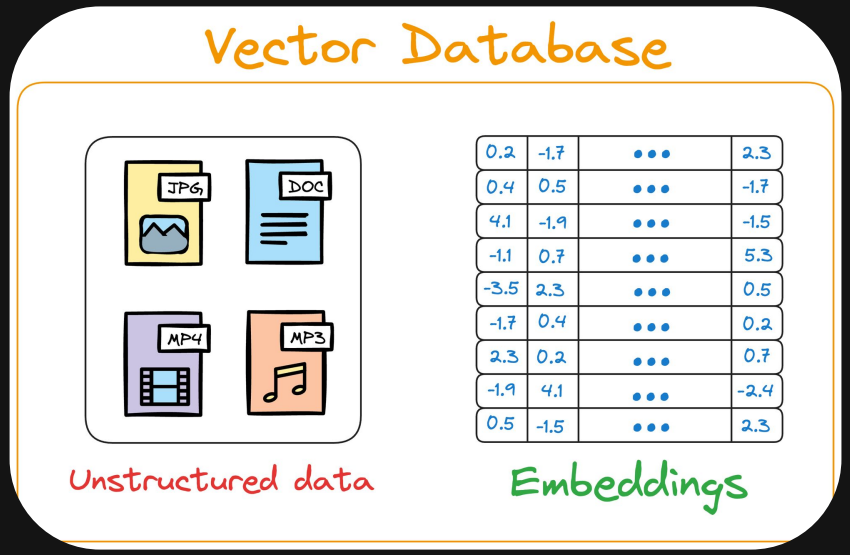

Vector Databases & RAG Pipelines

Büyük dil modellerinin (LLM) sınırlı bilgilerini aşmak ve halüsinasyonlarını engellemek için, metinleri vektör veritabanlarında arayıp modele dış veri sağlayan Retrieval-Augmented Generation (RAG) mimarilerinin veri mühendisliği bağlamında kurulması.

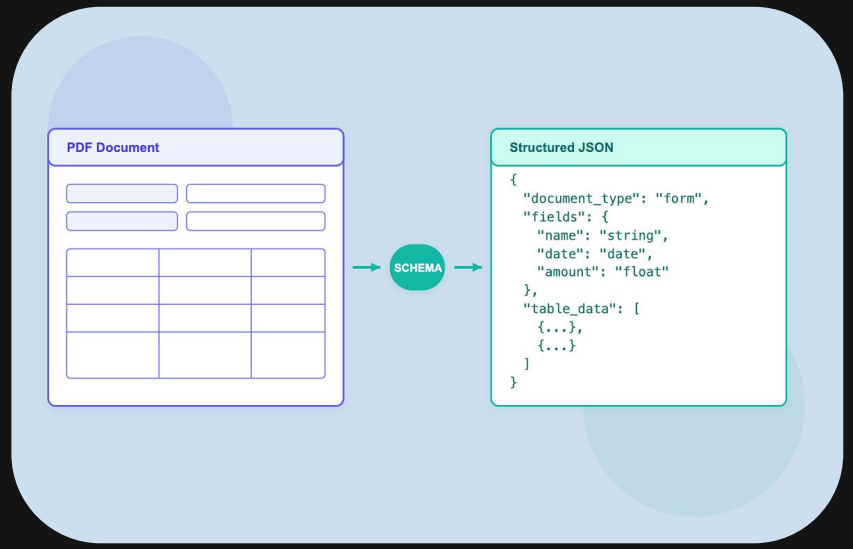

LLM-Assisted & Unstructured Data

Modelleri eğitmek ve test senaryoları yaratmak için sentetik veri üretimi, Text-to-SQL ile veriye erişimi demokratikleştirme ve metin, ses, görüntü gibi yapılandırılmamış verilerin GenAI ile anlamlandırılıp veri ambarlarına entegre edilmesi.

Bölüm 11: Q&A

Eğitim Özeti, Soru - Cevap ve Kapanış